Questionário (ref. Aulas 01 a 08)

Capítulo I – O que é PLN

1) O que é Processamento de Linguagem Natural?

Área da Inteligência Artificial que desenvolve métodos computacionais para analisar, compreender e gerar linguagem humana (texto ou fala).

2) Explique o que é polissemia (ambiguidade) e dê um exemplo.

A ambiguidade acontece quando uma mesma palavra expressa vários significados. Por exemplo: banco, manga etc.

3) Explique o que é sinonímia (variabilidade) e dê um exemplo.

A sinonímia acontece quando um significado pode ser expresso por mais de uma palavra. Por exemplo: carro, automóvel, veículo etc.

4) O que é dependência de contexto em PLN?

O significado de uma palavra depende das palavras ou da situação ao redor. Por exemplo: "banco" em "sentei no banco" vs. "fui ao banco". A dependência de contexto surge justamente porque existem fenômenos como polissemia e sinonímia.

5) Cite três tarefas (ou problemas) específicos de PLN.

Classificação de textos, análise de sentimento, reconhecimento de entidades nomeadas, identificação de tópicos, sumarização etc.

6) O que é classificação supervisionada de textos?

Envolve determinar a que categoria pertence um texto levando em consideração textos já rotulados. Ou seja, treinar um modelo com textos rotulados para prever a classe de novos textos.

7) O que é análise de sentimento?

Atribuir uma emoção, polaridade ou sentimento a um texto, geralmente positivo, negativo ou neutro.

8) O que é o reconhecimento de entidades nomeadas?

Identificar palavras no texto que representam entidades tais como pessoas, organizações, locais, datas etc.

9) O que é identificação de tópicos?

Método que identifica automaticamente os principais temas presentes em um conjunto de textos.

10) O que é um corpus em PLN?

Conjunto estruturado de textos usado para treinamento, análise ou avaliação de modelos de linguagem. Pode ter diferentes granularidades, tais como frases, parágrafos, páginas, artigos ou até livros inteiros.

Questionário (ref. Aulas 01 a 08)

Capítulo II – Processo de análise de dados

1) Historicamente, o processo de análise de dados foi estruturado em etapas que organizam o trabalho desde o entendimento até a interpretação dos resultados. Cite exemplos de modelos/metodologias.

KDD Process (Knowledge Discovery in Databases): processo de descoberta de conhecimento em bases de dados que envolve seleção dos dados, pré-processamento, transformação, mineração de dados e interpretação/avaliação dos resultados. CRISP-DM (Cross Industry Standard Process for Data Mining): metodologia de mineração de dados com seis etapas principais: entendimento do negócio, entendimento dos dados, preparação dos dados, modelagem, avaliação e implantação. SEMMA (Sample, Explore, Modify, Model, Assess): metodologia usada em mineração de dados criada pelo SAS (originalmente significava Statistical Analysis System) que inclui amostragem dos dados, exploração inicial, modificação/preparação, construção de modelos e avaliação do desempenho dos modelos.

2) No curso adotamos um ciclo de vida para projetos de análise de dados composto por seis macroetapas. Quais são essas etapas?

No curso adotamos as etapas: entender, preparar, processar, analisar, compartilhar e implementar.

3) Qual é o objetivo da etapa Entender em análise de dados?

Definir o problema analítico e as perguntas que serão respondidas com os dados. Em PLN, por exemplo, definir se o objetivo é classificar textos, identificar sentimentos ou identificar tópicos.

4) Qual é o objetivo da etapa Preparar em análise de dados?

Identificar e viabilizar as fontes de dados. Verificar se os dados existem, onde estão armazenados, como acessá-los, questões de governança, privacidade e autorização de uso. Em PLN envolve localizar os dados e definir como o corpus será construído, acessado e manipulado.

5) Qual é o objetivo da etapa Processar em análise de dados?

Realizar a limpeza e verificação técnica dos dados para garantir qualidade antes da análise. Em PLN isso envolve tarefas independentes do modelo, como remoção de duplicatas, correção de erros de transferência ou manipulação, tratamento de caracteres inválidos, identificação de dados ausentes e redução de ruído no texto. Enfim, atividades que garantam consistência do corpus sem alterar características linguísticas que podem ser relevantes para determinadas tarefas.

6) Qual é o objetivo da etapa Analisar em análise de dados?

Aplicar métodos analíticos e construir modelos para extrair padrões ou realizar previsões a partir dos dados. É nessa etapa que técnicas de

machine learning são efetivamente utilizadas. Em PLN isso pode envolver atividades de engenharia de atributos, como segmentação (tokenização), normalização textual, extração de informações e representação vetorial de texto, além do treinamento, avaliação e teste de modelos em problemas como classificação de textos, análise de sentimentos, reconhecimento de entidades, identificação de tópicos, entre outros.

7) Qual é o objetivo da etapa Compartilhar em análise de dados?

Comunicar os resultados da análise de forma clara para apoiar interpretação e tomada de decisão. Essa etapa normalmente envolve a integração com ferramentas de visualização e comunicação de dados, como Tableau ou Microsoft Power BI. Em PLN isso pode incluir a apresentação de métricas de desempenho dos modelos, exemplos de classificações realizadas ou visualizações que evidenciem padrões presentes no corpus.

8) Qual é o objetivo da etapa Implementar em análise de dados?

Aplicar os resultados da análise em um contexto real de uso. Essa integração pode ocorrer de diferentes formas, como a geração pontual de resultados a partir do modelo, execuções periódicas em processos automatizados (lotes) ou integração direta em sistemas que realizam inferência em tempo real. Em PLN isso pode significar integrar um modelo treinado, como um classificador de textos ou sistema de análise de sentimentos, em aplicações ou fluxos que utilizem dados textuais.

Questionário (ref. Aulas 01 a 08)

Capítulo III – Engenharia de atributos

1) O que é engenharia de atributos?

Processo de transformar dados já estruturados e com qualidade adequada em representações úteis para modelos analíticos ou de machine learning. Em PLN, a engenharia de atributos envolve a transformação de textos do corpus em atributos que possam ser processados por algoritmos. Utilizamos a expressão "engenharia de atributos" como um conceito guarda-chuva para designar qualquer transformação orientada ao modelo, isto é, decisões que moldam os dados para torná-los adequados a uma tarefa específica de PLN.

2) O que é segmentação (ou tokenização)?

Processo de dividir um texto em unidades menores chamadas tokens, que podem ser palavras, subpalavras ou outros elementos linguísticos.

3) Explique esses tipos de segmentação:
    a. Por palavra

    Divide o texto diretamente em palavras. Ex.: "Processamento de linguagem natural" → Processamento / de / linguagem / natural

    b. Por subpalavra

    Divide palavras em partes menores para lidar melhor com vocabulário grande ou palavras desconhecidas. Ex.: "infelizmente" → in / feliz / mente

4) O que é normalização?

Conjunto de técnicas usadas para padronizar ou simplificar o texto, reduzindo variações linguísticas que podem dificultar a análise (remoção de stop-words, stemming ou lematização, entre outras). Normalização reduz a complexidade do texto (menos variações, menos tokens distintos), o que simplifica o processamento e o espaço de representação.

5) Explique esses tipos de normalização:
    a. Remoção de stop-words

    Remoção de palavras muito frequentes e pouco informativas, como "de", "a", "o", "que". Profissionais experientes frequentemente adaptam ou constroem suas próprias listas de stop-words, porque a relevância das palavras depende do domínio, do corpus e da tarefa.

    b. Stemming

    Redução de palavras ao seu radical aproximado (é uma espécie de "truncamento"). Ex.: "correndo", "correu", "correr" → corr.

    c. Lematização

    Redução da palavra à sua forma base (lema), considerando a estrutura linguística. Ex.: "correndo", "correu" → correr. A lematização tende a ser mais usada que stemming, pois preserva a

forma linguística correta da palavra e, portanto, mais informação significativa para o modelo.

6) O que é extração de informação?

Processo de identificar automaticamente informações estruturadas dentro de textos não estruturados. Extração de informação tende a enriquecer os dados, adicionando anotações ou atributos (tags POS, entidades, relações etc.), o que aumenta a quantidade de informação disponível para o modelo e pode ampliar o espaço de representação.

7) Explique esses tipos de extração de informação:
   a. POS Tagging

   Rotulagem das palavras de acordo com sua classe gramatical (substantivo, verbo, adjetivo etc.).

   b. NER

   Identificação de entidades relevantes no texto, como pessoas, organizações, locais ou datas. O NER pode ser tanto um problema de PLN por si só quanto uma etapa dentro de um pipeline maior de análise textual, quando aparece como atividade auxiliar em outros problemas de PLN, como classificação de textos, análise de sentimento, identificação de tópicos, sistemas de busca ou organização de documentos, entre outros.

Questionário (ref. Aulas 01 a 08)

Capítulo III – Engenharia de atributos (Representação vetorial)

1) O que é representação vetorial?

Forma de representar dados textuais como vetores numéricos, permitindo que algoritmos de machine learning possam processá-los.

2) O que são representações esparsas?

Representações vetoriais em que a maioria dos valores é zero, ocorrendo quando o vocabulário é grande, mas cada documento utiliza apenas uma pequena parte das palavras. É comum em métodos mais tradicionais de PLN baseados em vetores, como One-Hot, Bag-of-Words e TF-IDF.

3) Qual é a ideia central da representação One-Hot ao representar palavras em um vocabulário?

Representar palavras como um vetor binário em que apenas uma posição é 1 (indicando a palavra no vocabulário) e todas as outras posições são 0. Ou seja, cada palavra ocupa uma posição fixa no vetor e é identificada apenas pela posição onde aparece o valor 1.

4) Qual é a ideia central da representação Bag-of-Words (BoW) ao representar documentos em um corpus?

Representar um documento pela frequência das palavras presentes, ignorando a ordem em que aparecem no texto. Isto é, o documento passa a ser descrito apenas pela contagem de palavras que aparecem nele.

5) Qual é a ideia central da representação TF-IDF ao ponderar palavras em um corpus de documentos?

Atribuir pesos às palavras considerando sua frequência no documento (TF) e sua raridade no corpus (IDF), destacando termos mais informativos e reduzindo o peso de palavras muito comuns. Palavras que aparecem muito em um documento, mas pouco nos demais, recebem maior importância.

6) Considere o seguinte *corpus* com três documentos: D1: eu gosto de dados; D2: eu gosto de ciência; D3: dados e ciência. Utilizando bigramas (n = 2), liste os bigramas gerados em cada documento.

D1: eu gosto de dados → eu gosto, gosto de, de dados
D2: eu gosto de ciência → eu gosto, gosto de, de ciência
D3: dados e ciência → dados e, e ciência

Questionário (ref. Aulas 01 a 08)

7) Ainda com relação ao *corpus* anterior, calcule o DF e o IDF de cada bigrama. Calcule o TF-IDF para os bigramas do documento D1.

Corpus com N = 3 documentos.

DF (Document Frequency)

Bigram	DF
eu gosto	2
gosto de	2
de dados	1
de ciência	1
dados e	1
e ciência	1

IDF

(IDF = log(N / DF), usando log natural)

Bigram	IDF
eu gosto	log(3/2) ≈ 0.405
gosto de	log(3/2) ≈ 0.405
de dados	log(3/1) ≈ 1.099
de ciência	log(3/1) ≈ 1.099
dados e	log(3/1) ≈ 1.099
e ciência	log(3/1) ≈ 1.099

TF-IDF em D1

Bigram	TF	IDF	TF-IDF
eu gosto	1	0.405	0.405
gosto de	1	0.405	0.405
de dados	1	1.099	1.099

Questionário (ref. Aulas 01 a 08)

8) Considere o corpus abaixo:

A: *The dog runs in the park*

B: *The cat runs in the garden*

A partir do corpus, calcule:

a. Calcule TF de cada termo em A e B.
b. Calcule DF de cada termo.
c. Calcule IDF de cada termo.
d. Calcule TF-IDF para cada termo em A e B.

Corpus com N = 2 documentos.

Termo	TF(A)	TF(B)	DF	IDF = log(2/DF)	TF-IDF(A)	TF-IDF(B)
the	2	2	2	0	0	0
dog	1	0	1	0.693	0.693	0
runs	1	1	2	0	0	0
in	1	1	2	0	0	0
park	1	0	1	0.693	0.693	0
cat	0	1	1	0.693	0	0.693
garden	0	1	1	0.693	0	0.693

9) Considerando a frase “eu gosto de ciência de dados”, liste os unigramas, bigramas e trigramas contíguos (sequenciais) que podem ser gerados a partir desse texto.

Unigrama (n = 1) → eu, gosto, de, ciência, de, dados; Bigrama (n = 2) → eu gosto, gosto de, de ciência, ciência de, de dados; Trigrama (n = 3) → eu gosto de, gosto de ciência, de ciência de, ciência de dados

10) O que são representações baseadas em coocorrência estatística?

São representações que capturam relações entre palavras com base na frequência com que aparecem juntas em um corpus. A ideia central é que palavras que aparecem frequentemente no mesmo contexto tendem a possuir algum tipo de relação semântica.

11) Explique esse tipo de representação vetorial:

a. PMI

Mede o grau de associação entre uma palavra e o contexto em que ela aparece. O contexto (ou janela de contexto) é definido por um conjunto de palavras ao redor, que pode ter várias palavras. A ideia

é verificar se uma palavra aparece naquele contexto mais vezes do que seria esperado por acaso, indicando uma associação relevante no corpus. Quanto maior o PMI, maior a evidência de que as palavras possuem uma associação relevante no corpus.

12) O que é probabilidade conjunta?

É a probabilidade de dois eventos ocorrerem ao mesmo tempo, representada por $P(A \cap B)$, ou, simplesmente, P (A, B).

13) O que é probabilidade marginal?

É a probabilidade de ocorrência de um evento isoladamente, sem considerar outros eventos. Ex.: $P(A)$ ou $P(B)$.

14) O que significa dizer que dois eventos são independentes?

Significa que a ocorrência de um evento não altera a probabilidade de ocorrência do outro.

15) O que significa dizer que dois eventos são dependentes?

Significa que a ocorrência de um evento influencia a probabilidade de ocorrência do outro.

16) Se dois eventos A e B são independentes, qual relação deve valer entre $P(A)$, $P(B)$e $P(A \cap B)$?

Deve valer a relação $P(A \cap B) = P(A) \times P(B)$. Ou seja, a probabilidade conjunta desses eventos é igual ao produto das probabilidades marginais, o que indica que a ocorrência de um evento não afeta a probabilidade do outro. Exemplo: lançamento de uma moeda duas vezes seguidas.

17) Qual é a ideia central da medida PMI ao analisar pares palavra-contexto em um corpus?

Medir se uma palavra (word) aparece em determinado contexto (context) mais vezes do que seria esperado por acaso, indicando uma associação relevante entre a palavra e o contexto. Ou seja, se o contexto for formado por apenas uma palavra, estamos medindo a probabilidade de duas palavras (word, context) aparecerem juntas mais vezes do que apareceriam isoladamente.

18) Em modelos baseados em coocorrência, o que a matriz palavra-contexto representa?

Uma matriz que registra quantas vezes cada palavra (word) aparece em determinados contextos (context) dentro do corpus. Por convenção, as palavras aparecem nas linhas da matriz e os contextos nas colunas. Assim, cada célula indica quantas vezes a palavra da linha ocorreu no contexto da coluna. Ou seja, a leitura é feita sempre linha (word) → coluna (context).

19) Que problema do PMI o PPMI resolve?

O PMI (Pointwise Mutual Information) pode assumir valores negativos quando duas palavras aparecem juntas menos vezes do que seria esperado

por acaso. O PPMI (Positive Pointwise Mutual Information) resolve esse problema substituindo os valores negativos por zero, mantendo apenas associações positivas entre palavra e contexto.

20) Qual é a diferença conceitual entre representações baseadas em frequência lexical (BoW/TF-IDF) e representações baseadas em coocorrência (PMI/PPMI)?

BoW e TF-IDF representam textos contando a frequência das palavras nos documentos, tratando cada palavra de forma essencialmente isolada. Já representações baseadas em coocorrência, como PMI, analisam com que frequência uma palavra aparece junto de outras dentro de um determinado contexto, capturando relações entre palavras no corpus.

Questionário (ref. Aulas 01 a 08)

Capítulo IV – Especificação de modelos

1) Cite 2 modelos supervisionados clássicos utilizados em PLN.

Regressão Logística e Naive Bayes.

2) Cite 2 modelos não supervisionados clássicos utilizados em PLN.

LDA (Latent Dirichlet Allocation) e K-Means.

3) O que são algoritmos baseline no contexto de machine learning?

Baseline (ou linha de base) é um modelo inicial, simples e funcional, usado como referência antes da adoção de soluções mais complexas.

Regressão logística

4) O que é o modelo de regressão logística e por que ele é chamado de "regressão"?

É um classificador supervisionado que estima a probabilidade de um texto pertencer à classe positiva a partir de uma combinação linear das variáveis de entrada, aplicando uma função sigmoide (ou softmax) para obter probabilidades. Ele é chamado de "regressão" porque realiza regressão linear internamente ($z = w \cdot x + b$) antes de aplicar a função sigmoide (ou softmax). Ou seja, o termo "regressão" vem da transformação linear interna e não do fato de o modelo ser utilizado para prever valores contínuos, já que é aplicado em classificação.

5) Por que a regressão logística é muito usada como baseline em PLN?

Porque é um modelo simples, rápido e estável, que funciona bem com representações textuais esparsas como BoW e TF-IDF. Além disso, possui boa interpretabilidade, permitindo analisar o peso das palavras na decisão, o que facilita sua utilização como modelo inicial de referência em problemas de classificação de textos.

6) Como a regressão logística realiza a predição em PLN e qual é o papel da função sigmoide nesse processo?

O modelo calcula inicialmente uma combinação linear dos atributos ($z = w \cdot x + b$), cujo resultado pode variar de $-\infty$ a $+\infty$. Em seguida, aplica a função sigmoide para transformar esse valor em uma probabilidade entre 0 e 1, que representa a chance de o texto pertencer a uma determinada classe e é utilizada na decisão final.

7) Qual é a regra de decisão na regressão logística? Este limiar é fixo?

A regressão logística produz a probabilidade de uma observação pertencer à classe positiva (classe 1). A decisão final é feita comparando essa probabilidade com um limiar (geralmente 0,5). Valores acima do limiar são classificados como classe positiva, e abaixo, por consequência, como classe

negativa. Esse limiar não é fixo e pode ser ajustado (ex.: 0,3 ou 0,7) conforme o contexto do problema (custo do erro etc.).

8) O que significa o custo do erro neste contexto?
O custo do erro refere-se ao impacto de classificações incorretas (falsos positivos e falsos negativos) no problema. Em PLN, alguns problemas possuem baixo custo de erro (ex.: classificação de texto simples), enquanto outros possuem alto custo (ex.: fraude). O limiar deve ser ajustado conforme esse custo e as regras de negócio: limiar mais baixo torna o modelo mais agressivo; limiar mais alto torna o modelo mais conservador.

9) O que é interpretabilidade no contexto de aprendizagem de máquina?
Interpretabilidade é a capacidade de um modelo ser compreendido e explicado por humanos, incluindo como ele utiliza as variáveis para gerar suas previsões. Modelos clássicos tendem a ser mais interpretáveis do que modelos modernos, como redes neurais.

10) É possível utilizar regressão logística com embeddings?
Sim. Porém, não é a combinação mais adequada, pois embeddings são representações que capturam relações semânticas complexas que a regressão logística, por ser um modelo linear, não consegue explorar plenamente. Por isso, em cenários de baseline, é mais comum utilizar regressão logística com representações clássicas como BoW ou TF-IDF.

Naive Bayes

11) O que é o modelo Naive Bayes e por que ele é chamado “naive”?
É um classificador supervisionado baseado no Teorema de Bayes que calcula a probabilidade de uma classe a partir das palavras do texto, assumindo independência entre elas. Ele é chamado “naive” (ingênuo) porque essa suposição de independência não é realista na linguagem natural, mas simplifica os cálculos e torna o modelo eficiente.

12) Por que o Naive Bayes é muito usado como baseline em PLN?
Porque é um modelo extremamente simples e rápido, que funciona bem com representações textuais esparsas como BoW e TF-IDF, mesmo em cenários com poucos dados. Por ter baixo custo computacional, costuma apresentar bom desempenho em tarefas básicas de classificação de textos.

13) O que é o Teorema de Bayes e por que ele é útil em PLN?
É um teorema que permite calcular uma probabilidade difícil a partir de probabilidades mais simples. Formalmente, ele reescreve $P(y|x)$ (probabilidade da classe dado o texto) em termos de $P(x|y)$ e $P(y)$, que são mais fáceis de estimar. Em PLN, isso é útil porque é mais viável calcular a probabilidade das palavras dado a classe do que o inverso.

Questionário (ref. Aulas 01 a 08)

14) Como o Naive Bayes classifica um texto?

Utilizando o Teorema de Bayes, o modelo calcula a probabilidade de cada classe dado o texto, ou seja, P(y|x). Como essa probabilidade é difícil de estimar diretamente, ela é reescrita em termos de P(x|y) (probabilidade das palavras dado a classe) e P(y) (probabilidade da classe). Assumindo independência entre as palavras, o modelo calcula P(x|y) como o produto das probabilidades individuais de cada palavra do texto dado a classe. Em seguida, combina esse valor com P(y) e compara os resultados para cada classe, escolhendo aquela com maior probabilidade como previsão final.

15) Qual é a principal limitação do Naive Bayes e em que situações ela impacta (ou não) o desempenho?

A principal limitação é a suposição de independência entre as palavras, que ignora relações de contexto e pode prejudicar o desempenho em casos onde o significado depende da combinação de termos, como em "não gostei muito". Por outro lado, essa simplificação reduz a complexidade do modelo e a necessidade de dados, sendo vantajosa em cenários com poucos dados ou quando palavras individuais já são bons indicadores da classe, como na detecção de spam.

16) De que depende, principalmente, a escolha entre Regressão Logística e Naive Bayes em PLN?

Depende principalmente da quantidade e qualidade dos dados disponíveis: com poucos dados, o Naive Bayes tende a performar melhor, enquanto com mais dados a regressão logística costuma apresentar melhor desempenho. Em segundo lugar, depende da adequação da suposição de independência entre as palavras: o Naive Bayes assume essa independência, enquanto a regressão logística não. Isso impacta o desempenho em tarefas com forte dependência contextual, como análise de sentimento ("não gostei") ou interpretação de frases ambíguas, onde a combinação de palavras altera o significado. Por outro lado, em tarefas menos dependentes de contexto, como detecção de spam (ex.: presença de "free", "promoção"), essa limitação tende a ter menor impacto.